Tarea 1 – Analítica de Datos

Análisis de Mercado y Modelo Predictivo para una Nueva Empresa de Telefonía Móvil

Contexto:

Una emprendedora ha comenzado su propia empresa de telefonía móvil y quiere dar una pelea dura a las grandes empresas como Samsung, Apple, Xiaomi, etc. Para esto debe realizar un estudio sobre los precios de ventas de sus competidores. En un comienzo, ella contrato a una empresa consultora quien le está realizando un estudio de mercado, técnico y financiero, sin embargo, también le gustaría respaldar este estudio con datos solidos que demuestren la diferencia de los precios de ventas de sus competidores a nivel de tienda y de marca. Ella no tiene conocimientos de Análisis de Datos y de Machine Learning, por ende, lo/la contrata a usted para que realice este proyecto.

En primer lugar, ella le comenta que no cuenta con una base de datos disponible para realizar algún análisis y que le gustaría obtener información actualizada del precio al cual están vendiendo los productos sus competidores. Asimismo, otro de los problemas iniciales que le surgió, es que no sabe cómo estimar el precio de los móviles que fabricará su empresa y que no le gustaría simplemente asumir precios. Por lo tanto, le pide a usted lo siguiente:

1) Que le genere una base de datos estructurada con información actualizada de la competencia que permita análisis interesantes.
2) Una vez recopilados los datos de ventas de teléfonos móviles de varias empresas, le pide que averigüe alguna relación entre las funciones de un teléfono móvil (p. ej., RAM, memoria interna, etc.) y su precio de venta.

El Desafío:

La emprendedora enfrenta dos problemas principales:

1. No posee una base de datos actualizada con los precios y características de los celulares de la competencia.
2. No sabe cómo estimar un precio competitivo para sus futuros modelos basándose en sus características técnicas.

Tus Objetivos:

Objetivo 1: Creación de una Base de Datos y Análisis Exploratorio (26 ptos)

Deberás construir una base de datos estructurada mediante web scraping desde el sitio https://www.solotodo.cl/celulares**:**

1. **Instrucción de Scraping:** Extrae toda la información directamente sin limpiar y guarda los datos RAW en un archivo llamado data_raw.csv, data_raw.pickle o data_raw.parquet **(10 ptos)**. Para cada modelo de celular, extrae la información de la variante que la página muestra por defecto al hacer clic en él (generalmente, la primera opción de

"Capacidad/RAM y color"). Deberán extraer todas las **características, características avanzadas, accesorios, los precios en las diferentes tiendas y si es reacondicionado o no.**

Para simplificar usaremos el nombre del producto como **identificador único**. Por ejemplo: Huawei P30 Pro (256 GB / 8 GB / Aurora).

2. **Limpieza de Datos:** Una vez extraídos los datos, deberás realizar un proceso de limpieza y preprocesamiento, conocido como **Data Wrangling (10 ptos)**. Esto incluye:
    - Manejar valores faltantes (NaN) de manera justificada.
    - Estandarizar las unidades de medida en cada columna (ej. todos los pesos en gramos, todas las capacidades de batería en mAh).
    - Procesar datos en formato de texto para extraer valores numéricos (ej. de "6.5 pulgadas" extraer 6.5, de "1080 x 2400 pixeles" extraer los valores numéricos).

    Para no realizar este ejercicio tan tedioso, les vamos a pedir que limpien solo las siguientes columnas:

    - **Precio normal:** El precio listado en cada tienda que diga precio normal o bien con todo medio de pago.
    - **Precio oferta:** El precio listado en cada tienda que diga con precio de tarjeta o bien con precio cupón.
    - **Marca:** El fabricante del celular (ej. Samsung, Apple, Huawei).
    - **Memoria Interna (GB):** El valor numérico del almacenamiento. *(Ej: de "128 GB" obtener 128)*.
    - **RAM (GB):** El valor numérico de la memoria RAM. *(Ej: de "6 GB" obtener 6)*.
    - **Dimensión de Pantalla (Pulgadas):** El tamaño de la pantalla en pulgadas. *(Ej: de '... 6.1" ...' obtener 6.1)*.
    - **Cámara Principal (Suma de MP):** La suma total de los megapíxeles de las cámaras traseras. *(Ej: de "Estándar 48.0 MP + Gran angular 12.0 MP" obtener 60.0)*.
    - **Cámara Frontal (MP):** Los megapíxeles de la cámara frontal.
    - **Batería (mAh):** La capacidad de la batería. *(Ej: de "3349 mAh" obtener 3349)*.
    - **Peso (g):** El peso del dispositivo en gramos.
    - **NFC (Sí/No):** Si el dispositivo cuenta con conectividad NFC.

Al final del proceso de limpieza y filtrado de columnas deberás guardar otro archivo que se llame data_processed.csv, data_processed.pickle o data_processed.parquet que contenga los datos limpios, junto con el identificador.

3. Una vez que tu base de datos esté limpia, responde las siguientes preguntas **(2 ptos c/u)**:

    a) Para las 3 marcas con el **precio promedio más alto** (considerando el precio de un mismo modelo en distintas tiendas), presenta sus estadísticas descriptivas (media, desviación estándar, mínimo, máximo, cuartiles) y **haz una pequeña interpretación**. Utiliza solo los precios en ofertas de los celulares no reacondicionados.
    b) Filtra tu base de datos para incluir únicamente los celulares vendidos por las tiendas **Ripley, Falabella y Paris**. Compara el precio promedio de los celulares en cada una de estas tres tiendas y determina cuál es, en promedio, la más cara y cuál la más barata. Utiliza solo los precios en ofertas de los celulares no reacondicionados. **Haz una pequeña interpretación.**
    c) Muestra cuántos modelos de celular únicos ofrece cada marca en el mercado (sin contar el mismo modelo vendido en diferentes tiendas). Presenta esta información en un **gráfico de barras** ordenado de mayor a menor. **Haz una pequeña interpretación.**

Objetivo 2: Modelo de Clasificación de Precios (24 ptos)

Este problema lo abordaremos como un problema de clasificación en vez de uno de regresión, por lo tanto, debes crear un modelo que prediga a qué rango de precios pertenece un celular en función de las características que recolectaste.

1. **Creación de la Variable Objetivo (Etiquetas) (2 ptos):**
   Usando el archivo data_processed que guardaste, crea una nueva columna en tu dataset llamada rango_precio usando los siguientes intervalos:

Etiqueta	Precio	Rango
0	Muy bajo	[0 – 100.000)
1	Bajo	[100.000 – 200.000)
2	Medio	[200.000 – 320.000)
3	Alto	[320.000 – 570.000)
4	Muy alto	[570.000 – más)

2. **Desarrollo y Evaluación del Modelo (22 ptos):**

    - Divide tus datos en un conjunto de **entrenamiento (80%) y de test (20%)**. Del 80% de entrenamiento extrae **80% para entrenar** el modelo y el otro **20% para validar (5 ptos).**

- Entrena al menos **dos algoritmos de clasificación** diferentes buscando sus mejores hiperparametros y evaluando sobre los datos de validación (ej. Regresión Logística, Árbol de Decisión, Random Forest) **(7 ptos).**
- Luego de seleccionar los mejores hiperparametros de cada modelo usando los datos de validación, evalúa el rendimiento del mejor modelo sobre el conjunto de test. Debes presentar e interpretar la **matriz de confusión** y calcular métricas como **Accuracy, Precisión, Recall y F1-Score**. **(5 ptos)**
- Una vez obtenidas las métricas, realiza un breve análisis para entender los resultados que estas obteniendo. Concluye cuál de tus modelos funcionó mejor y cuáles parecen ser las características más influyentes para determinar el rango de precio de un celular. **(5 ptos)**

Consideraciones:

- **Uso de Inteligencia Artificial:** Se permite el uso de herramientas de IA (como ChatGPT, Co-pilot, etc.) como apoyo. **Sin embargo, eres 100% responsable del código que entregas**, es decir, debes ser capaz de explicar cualquier parte de tu proceso y justificar tus decisiones en caso de que se te **pregunte de manera oral**. El uso de estas herramientas debe potenciar tu aprendizaje, no reemplazarlo.
- **Esta estrictamente prohibido copiarse entre pares.**